软件项目报告

基于 RAG 的个人知识库
问答系统项目报告

项目名称　知屿个人知识库

项目版本　1.0.0

编制日期　2026 年 10 月 12 日

Python / LangChain / FAISS / Streamlit

OpenAI 兼容 API

摘要

针对学习笔记、技术文档和论文资料分散、依靠文件名或关键词难以定位具体知识的问题，本项目实现了一个面向个人本机使用的知识库问答原型。用户导入 PDF 或 TXT 后，系统完成文本读取、规范化清洗、递归分段和来源信息记录，通过 Embedding 接口将片段转换为向量，并使用 FAISS 建立本地索引。提问时，系统用相同的向量模型编码问题，检索相关片段，按数量、相似度和上下文预算筛选资料，再把参考资料与问题组合成 Prompt，交由兼容 Chat Completions 的模型生成流式回答。页面同时展示参考文件、PDF 页码、原文片段和相似度，方便用户核对依据。

本项目采用模块化 Python 结构。LangChain 负责文档对象、文本分段、模型适配和问答链组合；FAISS 原生接口负责向量索引；Streamlit 负责配置、导入、聊天和文档预览。系统通过文件内容哈希实现去重，通过索引配置签名避免不同模型或分段参数的索引混用，通过候选索引、临时文件和原子替换保护导入失败前的数据。离线模式使用确定性的词面哈希向量与原文摘录，便于在无密钥环境中验证流程；API 模式提供语义向量检索和大模型生成能力。

同日最近一次完整回归中，38 项自动化测试全部通过，Ruff 静态检查与依赖一致性检查通过。已完成真实 PDF 的 Embedding 导入记录；当前 API 索引快照包含 4 份文档、116 个片段，向量维度为 1024。真实问答模型的答案质量、检索准确率和响应时延仍需使用独立题集与实际服务继续评估，不能由自动化通过率直接推断。

报告依次介绍项目需求与定位、系统结构、各模块的实现原理、验证证据、关键知识点和工程注意事项，并给出复现流程、代码阅读路线及后续改进方案。项目适合作为入门级 RAG 工程实践，当前定位为单用户、小规模、本机运行的知识库问答系统。

关键词： 检索增强生成；文本分段；Embedding；FAISS；余弦相似度；提示词；流式问答；本地知识库

目录

摘要 2

第一章 项目概述 4

1.1 项目背景与目标 4
1.2 功能需求与验收目标 4
1.3 适用场景与实现边界 5
1.4 技术选型与职责分配 5

第二章 系统设计与实现 6

2.1 总体架构与数据流 6
2.2 目录结构与模块接口 7
2.3 文件读取与文本清洗 8
2.4 递归分段与来源元数据 9
2.5 Embedding 模型与向量归一化 10
2.6 FAISS 索引与相关片段检索 11
2.7 增量导入与本地持久化 12
2.8 上下文构建与生成式问答 13
2.9 Streamlit 页面与状态管理 14
2.10 配置加载与错误反馈 15

第三章 测试验证与结果分析 15

3.1 验证层次与测试环境 15
3.2 自动化测试覆盖 16
3.3 实际导入记录与当前索引快照 17
3.4 效果评价方案 18
3.5 结果解读与验证边界 19

第四章 关键方法与工程注意事项 20

4.1 方法与知识点对应关系 20
4.2 分段与检索参数的调试方法 20
4.3 API 配置与调用成本 21
4.4 数据安全与可信引用 22
4.5 资料维护与运行边界 22
4.6 项目特色与可陈述的工程成果 22

第五章 总结与后续完善 23

5.1 项目完成情况 23
5.2 后续改进顺序 23
5.3 推荐学习与讲解路线 24

附录 A 核心代码阅读索引 24

附录 B 部署演示与故障排查 26

附录 C 项目理解与答辩问题 28

参考资料 29

第一章 项目概述

1.1 项目背景与目标

个人学习资料通常分布在多份 PDF、笔记和技术文档中。传统文件搜索擅长查找文件名，关键词搜索擅长匹配字面表达，但用户往往只记得一个问题，未必记得原文使用的具体词语。直接向通用大模型提问，又无法保证模型了解个人资料中的细节，也难以确认答案究竟来自哪一份文档。

本项目的目标是把“打开很多文件寻找内容”转变为“提出问题并查看对应依据”。系统首先查找个人资料中的相关片段，再让模型基于这些片段组织答案。用户能够沿着引用回到文件和页码，检查回答是否有证据支持。RAG 的核心思路是把外部知识检索接入生成过程；本项目采用固定的检索后生成管线，并不复现原始研究中的联合训练机制。[R1]

本项目不训练大语言模型，也不修改现有模型的权重。导入资料主要更新外部索引，适合知识经常增补、规模较小、需要出处的个人学习场景。项目的工程重点是把文档处理、模型调用、向量检索、来源展示和异常处理连接成可运行流程。

1.2 功能需求与验收目标

表 1-1 功能需求与验收目标

功能	用户操作	系统应提供的结果
文档导入	选择 PDF 或 TXT 并导入	读取内容，跳过无效文件，报告新增与重复数量
知识检索	输入完整的自然语言问题	返回相关片段，并按相似度筛选
回答生成	在 API 模式提问	基于检索资料生成中文回答，逐步展示
证据核对	展开参考片段	显示文件名、PDF 页码、片段原文和相似度
本地恢复	重新打开页面或重启服务	恢复已经保存且配置兼容的索引
资料维护	增量导入或显式重建	去重；成功重建后用目标资料集合替换旧库
会话管理	清空记录或导出问答	清除当前会话记录，或下载带参考原文的 Markdown

验收需要区分两类目标。功能验收关注系统能否正确读入、保存、检索和展示资料；质量验收关注是否检索到真正有用的证据，以及生成结论是否受到证据支持。前者已经有自动化覆盖，后者需要另行建立标注题集和人工核对流程。

1.3 适用场景与实现边界

当前系统面向个人本机使用，适合课程笔记、可提取文本的论文 PDF、技术说明和小型资料集。运行时默认监听 127.0.0.1:8501。API 模式需要能够访问外部问答与向量服务；离线演示模式不需要密钥。

系统暂不提供 OCR、复杂表格理解、图片问答、用户身份认证、多人数据隔离、跨会话对话记忆、混合检索或重排序。一次提问只使用当前问题与本轮检索资料，界面显示的历史消息不会自动送入模型。因此，“继续解释上面的第二点”这类依赖前文的追问，应改写为包含主题的完整问题。

文件限制为单个 20 MB、每批 20 个，PDF 最多 500 页，知识库最多 10000 个片段。这些限制是原型的输入保护和规模约束，不代表经过压力测试的生产容量。

1.4 技术选型与职责分配

表 1-2 技术选型与职责分配

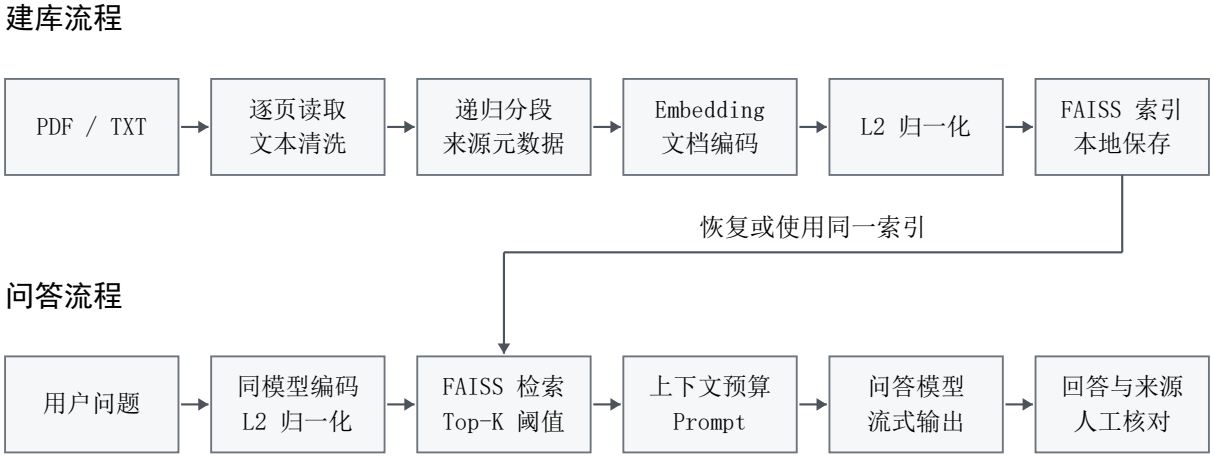
技术或组件	本项目中的职责	选择理由
Python	组织业务逻辑和数据处理	文档处理、模型 SDK 与向量生态较完整
pypdf	逐页提取 PDF 文本	能保留物理页序，便于来源追踪
LangChain Core	Document、Prompt、输出解析与链组合	统一模块输入输出，减少接口拼接代码
LangChain Text Splitters	按分隔符递归分段	支持字符预算、重叠及中文标点
LangChain OpenAI	适配向量与聊天 API	通过独立地址、密钥与模型名连接兼容服务
NumPy 与 FAISS	向量归一化和内积检索	小规模场景结构直观，检索结果便于验证
Streamlit	本机中文交互界面	用 Python 实现导入、配置、聊天和预览
pytest、httpx、Ruff	测试、模拟 HTTP、静态检查	验证真实客户端路径，避免测试消耗付费 API

本项目直接使用 FAISS 原生索引，而不是使用一个封装所有行为的向量数据库对象。这样可以明确控制向量顺序、元数据对应、保存格式和失败时的更新顺序，便于理解底层流程。

第二章 系统设计与实现

2.1 总体架构与数据流

系统包含建库流程和问答流程。建库负责把文件转换为可检索的向量与片段；问答负责把问题转换为查询向量，取回相关片段并生成回答。两条流程共享同一套 Embedding 配置和向量归一化规则。



文档编码与查询编码使用相同的模型和归一化规则

图 2-1 系统总体架构。 实线表示数据处理方向。API 模式的文档片段和问题会发往向量服务，问题及检索资料会发往问答服务；索引与提取文本保存在本机。

建库的关键产物不是“一个向量文件”而已，而是可相互定位的三部分：FAISS 索引、Document 片段列表、索引配置签名。索引返回第 i 个向量时，系统必须能取得片段列表的第 i 项，否则检索内容和显示来源可能错位。

问答时，系统先校验配置，再调用 KnowledgeBase.search() 取回 SearchHit 列表。prepare_answer() 按字符预算组织上下文并生成 PreparedAnswer。stream_answer() 根据运行模式返回原文摘录，或调用 Prompt、聊天模型与输出解析器组成的链。app.py 消费返回的文本片段，刷新页面并保存本轮消息。

2.2 目录结构与模块接口

```
RAG/
  app.py                    页面与会话交互
  rag/
    config.py               配置校验与索引签名
    documents.py            文件读取 清洗 分段
    providers.py            向量与聊天服务适配
    knowledge_base.py       索引管理 检索 持久化
    qa.py                   上下文 Prompt 流式回答
    errors.py               可展示的错误消息
    demo.py                 命令行离线演示
  tests/                    文档 检索 API 页面测试
  examples/                 三份中文示例资料
  data/indices/demo/        离线索引
  data/indices/api/         API 索引
  .streamlit/config.toml    本机监听 上传限制与主题
```

模块依赖方向保持相对清楚：页面调用业务模块，业务模块调用文档处理和模型适配，配置模块提供统一参数。qa.py 不直接操作上传控件，documents.py 不处理聊天记录，providers.py 不决定界面如何显示错误。这种分工使文档解析、向量算法和页面流程能够分别测试。

表 2-1 目录结构与模块接口

数据结构	主要字段	作用
Settings	模式、模型参数、分段与检索参数	统一配置，使用冻结 dataclass 避免原地修改
InputFile	name、content	封装上传文件，计算安全文件名和内容哈希
Document	page_content、metadata	同时保存片段文本与来源信息
VectorIndex	index、documents	维护向量位置与原文片段的一一对应
SearchHit	document、score	表示单条检索结果
PreparedAnswer	question、sources、context、mode	交接检索阶段与生成阶段
ImportReport	新增文件数、片段数、重复数、警告	将导入结果反馈给页面

Settings 使用 repr=False 隐藏密钥字段的普通对象表示，但这并不是密钥加密。程序仍需要在内存中持有密钥，才能发起合法的 API 请求。

2.3 文件读取与文本清洗

2.3.1 PDF 按页提取与页码保存

read_document() 用 BytesIO 读取上传字节，再通过 PdfReader 逐页调用 extract_text()。每个非空页面构造一个 Document，页码从 1 开始记录。跳过空白页后仍保留原物理页序，例如第二页有文字、第一页为空时，来源页码仍为 2，不会变成 1。

这里的页码是 PDF 文件中的物理页序，不一定等于文档印刷页脚中的编号。封面、目录和罗马数字页码都会造成差异。后续核对引用时，应以 PDF 阅读器中的页面位置为准。

pypdf 提取的是 PDF 中已有的文本对象，不是 OCR。只有图片的扫描件无法直接产生可检索正文。双栏、公式、表格、页眉页脚也可能被抽取成不理想的阅读顺序；能够读出文字，并不等于理解了原始版式。[R7]

读取前检查文件大小，解析时检查加密和页数。不能用空密码解密的 PDF 会被拒绝；损坏文件、无可提取文本的文件会得到具体提示。批量导入中的一个坏文件通常只产生警告，不阻止其他有效文件继续处理。

2.3.2 TXT 编码兼容与二进制识别

TXT 若带 UTF-16 字节顺序标记，使用 UTF-16 解码；否则依次尝试 UTF-8-SIG 和 GB18030。UTF-8-SIG 可以处理 UTF-8 BOM，GB18030 为常见中文编码提供兼容。程序还统计非换行、回车和制表符的控制字符比例，减少把二进制文件误当文本导入的情况。

文件扩展名限制并不能完全保证内容合法，因此系统同时检查扩展名、文件字节和解析结果。InputFile.safe_name 只保留文件名部分并清理不可打印字符，上传文件名不会被当作任意本地写入路径。

2.3.3 规范化与清洗的收益及代价

clean_text() 使用 Unicode NFKC 规范化，统一兼容字符形式；把 CRLF 和 CR 统一为换行；删除空字符、BOM 和零宽空格；压缩行内空白及连续空行。清洗可以减少视觉相同但编码不同的内容差异，并降低无意义空白对分段的影响。

清洗不是无损转换。例如全角字符可能变成半角，某些依赖精确空白的代码或表格会失去格式。系统保存的 start_index 指向清洗后页面文本的位置，不是原始 PDF 字节偏移。对于源代码、法律条款或必须逐字复核的材料，需要人工查看原文件。

2.4 递归分段与来源元数据

2.4.1 为什么需要把文档分成片段

整篇文档直接生成一个向量，会把多个主题混合在一起；整篇作为 Prompt 又可能超出模型上下文限制，增加费用和噪声。分段把检索粒度缩小到局部知识，使系统有机会只选择回答所需的资料。

项目使用 RecursiveCharacterTextSplitter，依次尝试段落、换行、中文句号、感叹号、问号、分号、空格等分隔符。只有较大单元仍然超长时，才进一步切成较小单元。字符递归切分及面向中文增加标点分隔符的原则可见 LangChain 文档。[R2]

默认 chunk_size 为 600，chunk_overlap 为 100，单位均为字符，而不是 token。重叠有助于保留跨边界的事实联系，但实际重叠由分隔符与拼接逻辑决定，不保证每两个片段都恰好重复 100 个字符。

2.4.2 分段参数如何影响效果

片段太短，问题的条件、结论或例外可能被分开；片段太长，主题混杂、检索定位变粗，也会占用更多上下文。重叠太少容易丢失边界信息，重叠太多会增加向量数量，并使 Top-K 被重复内容占据。因此，600/100 是原型默认值，不是适用于所有材料的最优参数。

例如，“先做向量归一化，再计算内积，此时内积等于余弦相似度”应尽量保留在相邻的局部上下文中。如果分段刚好把“归一化”条件与“内积等于余弦”结论分开，模型可能得到不完整依据。合理分段的目标是保留完整知识单元，而不仅是平均分配字符数。

2.4.3 元数据与片段唯一标识

表 2-2 递归分段与来源元数据

字段	含义	使用位置
source	清理后的文件名	引用标题、文档列表
file_hash	原始文件字节的 SHA-256	文件去重、版本区分、统计
page	PDF 物理页序；TXT 为 None	PDF 来源定位
start_index	片段在清洗后页文本中的起点	片段定位与 ID 构造
chunk_number	本次文件分段后的顺序号	预览辅助信息
chunk_id	来源哈希、页码、位置和文本组合的 SHA-256	检查重复片段和展示短 ID

文件去重依据原始字节，而不是文件名。相同内容改名后仍会被跳过；同名文件内容改变则作为新文档导入。两个语义相同但字节不同的文件不会自动合并，这不是语义去重。

2.5 Embedding 模型与向量归一化

2.5.1 向量模型与问答模型的分工

Embedding 模型接收文本，输出固定维度的数值向量，用于比较问题和资料的接近程度。问答模型接收问题与参考文本，生成自然语言答案。两者是独立任务，支持聊天接口的服务未必支持向量接口，不能把聊天模型名直接填进 Embedding 模型字段。

build_embeddings() 创建 OpenAIEmbeddings 并包装为 UnitEmbeddings。问答侧的 build_chat_model() 创建 ChatOpenAI。两套配置分别指定 API Key、Base URL 和模型名，因此可以由不同服务商提供。LangChain 的对应集成提供统一的客户端对象；具体第三方接口是否兼容仍需要实际验证。[R3][R6]

向量适配设置 check_embedding_ctx_length=False，使请求发送文本字符串，避免向 OpenAI 兼容服务发送只适合特定 tokenizer 的 token ID。这个设置同时意味着项目没有依赖客户端自动分割超长输入；仍须确保字符分段后的实际 token 数不超过服务限制。

2.5.2 归一化内积为何等于余弦相似度

设查询向量为 q，文档向量为 d。余弦相似度等于二者内积除以各自长度的乘积；当两者分别归一化到单位长度后，直接计算内积即可得到余弦相似度。[R4]

$$cos(q, d) = \frac{q \cdot d}{||q||\ ||d||} = q_norm \cdot d_norm$$

$$q_norm = q / ||q||, \quad d_norm = d / ||d||$$

式 2-1 余弦相似度与单位向量内积。 非零向量先归一化，才能把内积解释为余弦相似度。

UnitEmbeddings.normalize() 把返回值转换为 float32 矩阵，检查二维形状、非空维度和有限数值，再按行计算 L2 范数并相除。分母设置不小于 1e-12，以避免除零。零向量会保持为零，不能把它当成包含有效语义的单位向量。

文档与查询都必须经过同样处理。若只归一化一侧，文档向量长度仍可能影响分数。更重要的是，建库和查询必须使用同一套向量模型与表示方式；两个不同模型即使都输出 1024 维，也不意味着向量空间可以混用。

2.5.3 离线模式的实现与限制

DemoEmbeddings 将英文词语与中文连续字符中的二元、三元字符片段进行哈希，累计到固定的 2048 维桶中，再由 UnitEmbeddings 归一化。其结果确定、无需联网，适合验证流程、排序和保存恢复。

它没有通过语义训练学习同义表达，存在哈希碰撞，不能作为真实语义 Embedding 的质量替代。离线回答直接展示检索到的原文，界面会明确标记未调用大模型。离线成功说明管线可运行，不说明生成模型已经连接成功。

2.6 FAISS 索引与相关片段检索

2.6.1 IndexFlatIP 的选择

项目使用 faiss.IndexFlatIP。Flat 表示保存完整向量并逐个比较，IP 表示以内积为检索分数。经过双侧归一化后，这一分数可以用于余弦相似度排序。该索引属于精确检索，不需要预训练聚类中心，也没有使用 IVF、HNSW 或 PQ 近似索引。[R4][R5]

“精确检索”只表示在给定向量空间中准确找到最高分向量，不代表找到了业务上最正确的证据。向量模型不合适、分段不完整、问题过于模糊，都可能使精确计算返回不理想内容。

2.6.2 Top-K 与阈值过滤

search() 首先清理问题并限制长度为 2000 字符以内；知识库为空时返回空结果。有索引时，系统调用 embed_query() 生成并归一化查询向量，检查其维度，再向 FAISS 请求 min(K, N) 条结果，最后仅保留分数不低于阈值的片段。

默认 K=4，最低相似度为 0.12。K 是返回数量上限，阈值是最低向量相关程度；设置阈值后，返回数量可能少于 K，甚至为零。相似度在此不是概率，也不是答案置信度，更不是可对外报告的回答准确率。

系统按 FAISS 返回的向量位置取出对应 Document，封装为 SearchHit。当前没有重排序、来源多样性控制或相邻片段合并。因此，重叠较多的相似片段可能同时进入 Top-K，并挤占上下文预算。

2.6.3 复杂度与规模估算

若有 N 个 d 维向量，单次精确比较的主要计算量随 N×d 增长；纯 float32 向量数组的存储量约为 4Nd 字节。[R5] 当前 116×1024 维向量约占 464 KiB；10000×1024 维约占 39.1 MiB。这里是数组容量估算，不是实际进程内存或磁盘压缩文件大小。

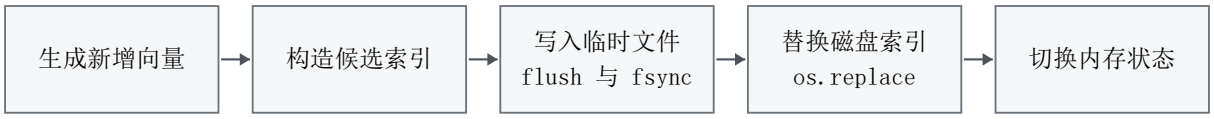
元数据、Python 对象、查询中间结果和候选索引克隆还会占用额外内存。API 网络请求和模型生成也可能主导端到端耗时。因此，不能只根据向量数组较小，就宣称系统具备高并发或毫秒级问答能力。

2.7 增量导入与本地持久化

2.7.1 增量导入的更新顺序

ingest() 先检查批量限制，收集已有 file_hash，再逐个读取新文件、分段和汇总警告。重复文件跳过，新增内容才调用 Embedding。若某个文件解析失败，其他有效文件可以继续；若没有任何可导入的新内容，则返回重复报告或抛出可读错误。

程序不会立即在活动索引上追加向量，而是构造候选索引。增量导入时克隆旧 FAISS 索引并复制文档列表；重建时创建新的空索引。新向量和新片段加入候选对象后，只有保存成功，self.store 才切换到候选对象。



提交前发生接口或写盘失败：保留旧知识库，显示错误

图 2-2 导入成功后的提交顺序。 向量接口失败或保存失败时，不把未完成的候选数据切换为当前活动知识库。

这种方式体现了事务式更新的思路：先准备新状态，再提交。但它不是数据库事务，也没有实现并发锁。两个进程或会话同时写同一路径，仍可能发生后写覆盖，因此当前应按单用户使用。

2.7.2 NPZ 文件中保存什么

_save() 用 faiss.serialize_index() 得到内存字节，再与 JSON 元数据一起保存到 knowledge.npz。元数据包括 schema 版本、配置签名、向量维度、更新时间、FAISS 字节的 SHA-256，以及各片段文本和 metadata。读取时使用 np.load(..., allow_pickle=False)，不反序列化 Python 文档对象。

写盘先在目标目录创建临时文件，flush 和 fsync 后调用 os.replace() 替换目标文件，最后清理临时文件。通过内存字节序列化还能减少 FAISS 直接处理中文路径时的兼容问题。

原始上传文件不会额外保存，但清洗后的片段原文会写入 NPZ。索引没有加密，不能把“没有保存原始 PDF”理解为“本机没有敏感内容”。SHA-256 校验用于发现字节变化，不提供加密，也不能防止有权限修改文件的人同时重写校验值。

2.7.3 索引恢复与配置一致性

load() 检查 schema、配置签名和二进制校验值，反序列化索引并重建 Document 列表，再检查片段 ID、向量数量、维度、内积度量及 IndexFlatIP 类型。索引损坏或不兼容时，页面阻止直接提问并给出重建提示。

配置签名包含 Embedding 的类型、服务地址和模型名，以及分段长度、重叠长度和预处理版本。密钥、聊天模型和检索阈值不写进签名：更换这些参数不会改变文档向量本身。更换 Embedding 或分段参数则需要恢复原配置，或用完整目标文件集合重建。

离线与 API 索引分别保存在 demo 和 api 子目录。两个模式既不共享向量维度，也不混用文件。当前仅维护每个模式的一份活动索引，没有多版本索引注册表或自动备份恢复机制。

2.8 上下文构建与生成式问答

2.8.1 从检索结果组织参考资料

prepare_answer() 为每条资料添加本轮引用编号、文件名和可用页码，再拼接正文。总预算默认为 10000 字符，预算同时考虑标题和片段间分隔符；最后一个片段可能被截断，后续片段可能因预算不足而不再加入。

页面显示的 sources 使用实际放入上下文的截断文本，避免出现“页面展示了一整段，但模型只看到了前半段”的证据错觉。引用编号仅在本轮回答内有效，不是全局文档 ID。

字符预算与模型 token 预算不是同一概念。英文、中文、代码和特殊符号的字符/token 比例不同，而且系统提示词、问题和生成回答也占用窗口。当前实现属于字符级限制，若要更精确控制费用和上下文长度，需要针对实际模型增加 token 统计。

2.8.2 Prompt 规则与链式组合

系统提示词要求模型用中文、仅依据本轮参考资料回答、资料不足时明确说明、重要结论标注引用、资料冲突时提示冲突，并要求把资料中的指令当作待分析数据。用户消息包含明确的资料起止标记和当前问题。

核心链的实际组合形式为：

```
chain = PROMPT | build_chat_model(settings) | StrOutputParser()
for token in chain.stream({"context": context, "question": question}):
    if token:
        yield token
```

管道符组合的含义是把上一步输出交给下一步：Prompt 构造消息，ChatOpenAI 调用模型，StrOutputParser 提取字符串。本项目没有使用自动规划、工具选择循环或复杂 Agent 状态图，固定 RAG 链已经能够覆盖当前需求。

2.8.3 无证据与引用可靠性

若筛选后没有来源，stream_answer() 直接返回“当前知识库中没有找到足够相关资料”的提示，不调用聊天模型。这样能减少没有依据时的额外生成，但不等于完整的可回答性识别：检索到了高相似片段，仍可能缺少问题所需的关键事实。

引用编号由模型生成，参考片段由检索管线提供。当前没有程序逐句核验“这一结论是否被这一引用支持”，也没有强制阻止模型输出不存在的编号。因此，Prompt 和来源展示只能帮助约束与复核，不能保证完全消除幻觉。

2.8.4 流式展示与中断处理

ChatOpenAI 使用 Chat Completions 接口，显式关闭 Responses API 路径及流式用量扩展。页面逐步消费文本，把已经收到的 pieces 拼接到占位区域。流式输出改善等待过程中的可见性，但不意味着模型总生成时间一定减少，也不保证每个 SDK 文本片段正好对应一个 tokenizer token。

发生网络中断时，页面保留已经显示的部分回答，并标记未完成。若模型没有返回任何有效文本，程序提示空回答。SDK 最多重试 2 次，不应据此承诺已开始的流可以自动续接；项目没有实现断点续写。

2.9 Streamlit 页面与状态管理

页面由侧边栏和三个标签页组成。侧边栏提供配置、文件选择、导入、示例加载与重建；知识问答页展示问题、回答与参考片段；我的文档页展示数量及预览；使用说明页解释模式和限制。

Streamlit 交互通常会触发脚本重新执行。st.session_state 用于在同一用户会话的 rerun 之间保留设置、知识库实例、已加载设置、消息和导入报告，这是会话状态机制的典型用途。[R8] 页面设置通过 form 一次提交，减少未完成配置被立即应用的情况。

应用检测到 Settings 与 loaded_settings 不同时，会创建 KnowledgeBase 并尝试恢复对应索引，同时清空当前对话。成功新增文档后也清空原对话，避免把旧知识库状态下的答案与新资料混在一起。仅重复导入、没有新增内容时，不需要重新生成已有文档向量。

对话记录只保存在当前会话。新会话能够恢复磁盘索引，但不会自动恢复旧聊天和页面填写的密钥。项目也没有用全局缓存保存密钥或活动文档；这减少跨会话混用风险，但共享磁盘路径仍不具备多人数据隔离。

文档预览按完整 file_hash 分组，标题显示短内容 ID。这样同名文件的不同版本会显示各自内容；仅按文件名查找第一条片段会误把所有版本都预览成第一版，这是本项目已经修复并加入回归测试的具体问题。

2.10 配置加载与错误反馈

Settings.from_env() 读取项目 .env，并保留已存在环境变量的优先级。LLM_* 与 EMBEDDING_* 配置独立；未填写专用密钥或地址时，可以使用 OPENAI_API_KEY 和 OPENAI_BASE_URL 作为公共后备。页面配置通过 dataclasses.replace() 生成新对象，经 validate() 后才应用。

validate() 检查模式、分段范围、重叠小于分段、Top-K、相似度、批量大小和超时。应用 API 设置时先允许保存尚未补齐密钥的配置，真正需要 Embedding 或聊天时再要求对应密钥与模型名。

地址校验拒绝常见控制台域名、完整资源路径，以及包含查询参数、锚点或登录凭据的 URL。Base URL 应是 API 前缀，不能把模型广场网页或已经包含 /embeddings 的完整接口地址直接当成前缀。校验只能排除已知错误，不能代替真实的网络连通与兼容性验证。

user_error() 将认证、限流、超时、连接失败、索引不兼容和文件错误转换为中文提示。对未知异常只记录类型和调用位置，不直接回显服务商响应、异常消息或局部变量，避免其中夹带密钥和文档内容。

第三章 测试验证与结果分析

3.1 验证层次与测试环境

项目把验证分为文档单元测试、知识库行为测试、真实客户端的模拟 HTTP 测试、Streamlit 页面测试和真实服务导入记录。不同层次回答不同问题，不能互相替代：模型客户端可以正确解析模拟 SSE，不代表实际服务一定可达；文档成功向量化，也不代表生成答案已经正确。

已验证环境为 Windows 和 Python 3.12.7，项目声明支持 Python 3.11 至 3.13。requirements.txt 规定依赖范围，requirements-lock.txt 固定一次已验证环境的完整版本。下表列出锁文件中的主要组件，便于复现，而不是要求读者追求网络上的最新版本。

表 3-1 验证层次与测试环境

组件	已锁定版本	说明
langchain-core	1.6.9	文档、Prompt 与可运行链
langchain-openai	1.7.0	向量与聊天客户端
langchain-text-splitters	1.1.3	递归字符分段

组件	已锁定版本	说明
faiss-cpu	1.15.1	CPU 向量索引
streamlit	1.65.0	本机交互页面
pypdf	6.20.0	PDF 文本提取
numpy	2.5.4	数组与向量计算
pytest / httpx	9.1.1 / 0.28.1	测试组织与模拟 HTTP

最近一次完整回归已得到 38 passed，静态检查结果为 All checks passed，依赖检查结果为 No broken requirements found。测试采用临时目录和独立知识库，不用实际密钥调用付费模型。受限 Windows 沙箱可能影响本机套接字和原生库加载；这类运行限制需要与应用逻辑失败分开判断。

3.2 自动化测试覆盖

表 3-2 自动化测试覆盖

测试文件	用例数	核心覆盖
test_documents.py	11	三种文本编码、清洗分段、PDF 页码、空文件、扫描、加密、损坏和错误类型
test_knowledge_base.py	10	排序、去重、增量与重建、写盘失败保护、中文路径、索引不兼容与损坏、无证据和预算
test_config.py	7	API 前缀、控制台网页、完整资源路径和含敏感参数的 URL 校验
test_api_pipeline.py	6	真实客户端请求结构、独立密钥地址、流式响应、归一化及异常信息保护
test_app.py	4	离线页面、API 成功与中断、重启恢复、同名版本预览
合计	38	参数化测试展开后的数量

38 个用例全部通过的含义是这些明确断言成立，并不等于 38 个真实用户问题都回答正确，也不是测试覆盖率 100%。项目没有以行覆盖率、检索召回率或人工正确率替代这些功能结论。

3.2.1 文档与知识库测试的关键证据

文档测试检查 UTF-8-SIG、UTF-16 和 GB18030 的中文内容；确认清洗规则、分段上限、来源哈希、有效 start_index 和唯一 chunk_id；通过构造含空白页的 PDF 验证页码没有重新编号。异常文件测试检查系统能给出具体原因，而不是无条件进入向量接口。

知识库测试使用主题不同的资料，验证相关片段位于前列；验证重复导入不增加文档，增量添加和完整替换有不同效果；模拟磁盘写入失败，检查内存和已保存文件仍是原版本；恢复中文路径下的索引后，检索结果应保持一致。

上下文测试限制字符预算，并检查显示来源中的文本确实出现在发送上下文里。无证据测试检查系统直接返回提示。索引测试检查模型或分段参数变化时拒绝误用旧库，损坏文件能够被识别。密钥测试检查保存元数据中没有 API Key。

3.2.2 模拟 HTTP 为什么具有价值

API 集成测试并非直接替换最终回答字符串，而是使用 httpx.MockTransport 提供模拟 HTTP 响应，同时运行真实的 LangChain 和 OpenAI 客户端。它检查请求分别发往 embedding.test 与 chat.test，授权头使用各自测试密钥，Embedding 输入为字符串数组，聊天请求包含参考资料、问题和 stream=true。

模拟 SSE 逐条返回模型文本，再由实际客户端解析为流式输出。测试还检查恢复索引后，不重新为已有文档生成向量。这种验证能够发现接口拼接和请求结构错误，但无法证明外部服务的额度、网络稳定性和模型能力。

3.2.3 页面成功与异常路径

Streamlit AppTest 在没有手工浏览器操作的情况下驱动页面组件，可设置聊天输入、点击按钮并检查渲染结果。[R9] 项目页面测试涵盖示例导入、回答、来源、导出控件和新会话恢复。

API 页面测试分别模拟正常结束与中途 ReadError。正常路径应展示完整回答和参考片段；中断路径应保留已生成文本、显示“未完成回答”提示、保存安全的错误信息，而不是静默把半截答案当成最终答案。同名文件版本测试验证两个预览标签不同，正文也分别对应各自内容。

3.3 实际导入记录与当前索引快照

已有真实服务验证记录中，E26106140096.pdf 通过硅基流动 BAAI/bge-m3 完成向量化，生成 112 个片段。报告编制时读取到的 API 索引已包含这份 PDF 和三份内置 TXT 示例，共 4 份文档、116 个片段，向量维度为 1024；配置签名中的分段长度为 600、重叠长度为 100。

表 3-3 实际导入记录与当前索引快照

检查项	当前证据	能说明什么
真实 PDF 向量导入	112 个片段的成功记录	文档处理与所配置向量接口曾完成真实调用
API 索引快照	4 份文档、116 个片段、1024 维	当前已保存的知识库规模与配置
浏览器离线问答	已展示原文摘录与来源	页面和本地检索管线可操作
生成式页面测试	模拟 HTTP 成功与中断均通过	客户端到页面的生成与异常处理路径可工作
真实问答质量	未纳入本次可核验评测记录	不能报告真实 DeepSeek 正确率或完整模型质量结论

116 个片段是特定资料、清洗规则和分段参数下的结果，不是固定的系统配置。换资料、改预处理、调分段都会改变数量。向量维度来自所选模型的接口输出，也不是项目强制固定为 1024。

此前导入失败的一个实际原因是把硅基流动控制台的模型网页当成 Embedding Base URL，接口返回的并非有效向量。修正为 API 前缀后导入成功。项目随后增加控制台地址和完整接口路径校验，并对 HTML 或不兼容向量响应给出可行动提示。这一案例说明，模型集成问题应先区分文档解析、接口地址、授权和响应结构，不能把所有异常都归因于 PDF。

3.4 效果评价方案

现有测试主要证明功能正确性。若要在课程报告或面试中报告“检索准确”“回答可靠”或“节省时间”，应额外建立固定题集。建议从资料中准备事实题、跨片段题、同义改写题、边界题和知识库外问题，并为每题标注参考答案及相关文件页码或原文范围。

题集应保留一部分作为最终测试集，调参时只使用开发集。相关依据最好锚定原文件页码和原文范围，而不是仅保存某次分段的 chunk_id，否则分段策略变化会让标注难以比较。重叠片段应避免被重复计算成多个独立相关事实。

表 3-4 效果评价方案

指标	计算或核对方式	使用条件
Hit@K	前 K 条中至少有一条相关依据的问题比例	适合每题至少有一处可回答证据的情况

指标	计算或核对方式	使用条件
Recall@K	每题取回的相关证据数 / 标注相关证据总数，再求平均	需要较完整的相关证据标注与明确计数单位
MRR	首条相关结果排名的倒数，再对问题求平均	关注相关依据是否排在前面
回答支持程度	将重要结论逐条与参考原文核对	不能只看语句是否流畅
引用正确性与覆盖	引用是否存在、支持结论；重要结论是否有依据	编号存在和证据充分是两个层次
无答案处理	对资料不足的问题检查是否明确说明	同时观察错误回答和过度拒答
响应耗时	分别记录查询向量、检索、首段输出、完整回答时间	多次运行，记录模型、网络与资料规模
调用成本	按服务商实际用量记录导入与每问消耗	字符数不能精确替代实际计费用量

可对比“关键词检索”“当前向量检索”“调整分段后的向量检索”，也可在允许使用模型的条件下比较无参考资料与有参考资料的回答。比较前应固定题目、资料版本和评价口径。本报告给出的是后续评价设计，没有把它写成已经完成的对照实验。

3.5 结果解读与验证边界

目前能够支持的结论是：项目已经打通文档处理、本地索引、检索、问答接口和页面展示流程，并对常见失败路径建立了自动化保护。它可以作为完整的个人知识库原型及工程学习项目。

目前不能支持的结论包括：适用于任意 PDF；保证回答无幻觉；已经在真实服务上达到某个准确率；支持生产级多人并发；所有异常都会自动恢复；比其他系统快某个百分比。这些说法分别需要版式、模型质量、评测、压力、故障注入和对照数据。

第四章 关键方法与工程注意事项

4.1 方法与知识点对应关系

表 4-1 方法与知识点对应关系

知识点	本项目中的具体运用	应理解的核心
RAG	先查知识库，再用证据生成回答	外部知识更新与模型权重更新不同
文本预处理	编码兼容、NFKC、空白清洗	规范化会改变表示，应保留来源
递归分段	标点优先、长度限制和重叠	粒度、语义完整性与成本的权衡
向量表示	文档与问题使用同一 Embedding	维度相同不保证语义空间相同
线性代数	L2 归一化、内积、余弦相似度	归一化条件决定分数的解释
信息检索	Top-K、阈值、相关结果排序	检索相关性不等于答案真实性
Prompt 设计	资料边界、缺证据提示、引用规则	提示词是约束手段，不是正确性证明
内容寻址	SHA-256 文件哈希与片段 ID	按内容识别资料，不依赖文件名
一致性保护	配置签名、维度与数量检查	避免向量、片段和配置错配
事务式更新	候选索引、临时文件、原子替换	成功提交前保留旧状态
API 集成	独立密钥地址、超时、流式响应	接口协议与模型角色都需匹配
软件测试	临时目录、MockTransport、AppTest	区分算法、接口、页面与真实效果

这些知识点的价值在于能够解释“为什么这样实现”和“什么条件下会失败”。面试或项目讲解时，单纯列出库名不如围绕一个问题说明数据流、设计取舍和验证证据。

4.2 分段与检索参数的调试方法

先建立少量已知答案问题，查看原文抽取质量，再决定是否调分段。若抽取内容已经错乱，单纯增大 Top-K 通常不能恢复丢失的结构。若证据被切断，应先调整分隔符、分段长度或邻接上下文；若证据完整但排序靠后，再考虑模型、查询表述或检索策略。

表 4-2 分段与检索参数的调试方法

参数	当前默认值	调大或调整时的主要影响
CHUNK_SIZE	600 字符	保留更多上下文，但向量主题可能更混杂
CHUNK_OVERLAP	100 字符	减少边界丢失，但重复与调用量可能增加
TOP_K	4	增加资料覆盖，也可能引入无关或重复片段
MIN_SIMILARITY	0.12	调高可减少低分结果，但可能漏掉相关资料
MAX_CONTEXT_CHARS	10000	增加资料预算，同时增加输入与窗口压力
EMBEDDING_BATCH_SIZE	16	影响单次请求规模，需匹配服务商限制
API_TIMEOUT	60 秒	允许较慢请求继续等待，不解决错误地址或余额问题

阈值应根据实际模型和题集校准。不同 Embedding 模型的分数分布可能不同，0.12 不是通用的“相关/不相关”分界。不要把阈值设得极低来掩盖检索问题，也不要仅为得到整齐的 K 条结果而接受明显无关片段。

分段参数变化会改变片段集合，因此需要重建文档向量；仅调整 Top-K、阈值或聊天模型不需要重算已有向量。一次只改一类因素，保留题集、配置和结果记录，才能判断变化来自哪里。

4.3 API 配置与调用成本

Base URL、模型名和密钥是三项独立条件。地址应填写接口前缀；模型名必须是对应服务支持的模型标识；密钥必须属于该服务并有权限和额度。问答可用但导入失败时，应检查 Embedding 配置，而不是反复更换聊天模型。

建库通常会为新增片段调用向量接口；每次提问会调用一次查询向量流程，有相关资料时再调用聊天模型。恢复索引本身不需要重新生成文档向量。内容哈希去重减少重复导入费用，但重建会为目标集合重新生成向量。

即使输入只有 600 字符，仍需要核对向量服务的 token 上限与批量限制；若接口限制每批输入数较小，可以降低 EMBEDDING_BATCH_SIZE。不能把所有 400 或 404 错误都用“批量设为 1”解决，首先应看地址前缀、模型名与接口类型。

服务超时和最多两次重试可能延长总等待时间，API_TIMEOUT 不是整个问答流程的总时长上限。并发、限速、退避策略和配额监控是后续扩展时需要另行设计的能力。

4.4 数据安全与可信引用

API 模式会把提取的文档片段发送给向量服务，把问题发送给向量服务，并把问题及检索资料发送给问答服务。索引在本地保存，并不等于整个系统的数据处理完全离线。使用个人、组织或保密资料时，应先确认允许发送到所配置的服务。

当前密钥默认只保存在会话；若写进 .env，则属于本机明文配置，需要做好文件权限和版本控制排除。不能把真实密钥放进报告、截图、源代码或可分享压缩包。日志只记录必要调用位置的做法有助于降低泄露，但仍应检查后续新增日志是否输出敏感内容。

文档中的恶意指令可能试图覆盖问答规则。项目在系统提示词中要求将参考资料作为数据处理，但没有完整的提示词注入检测或权限控制。来源展示可以帮助人工发现问题，不能作为自动安全证明。

NPZ 使用 allow_pickle=False、校验值和元数据检查，能够减少错误反序列化与意外损坏风险。它仍不是一个面向不可信第三方索引的安全导入格式。当前设计应读取程序自己生成且来源可信的索引，不应把任意外部 NPZ 当成安全文件加载。

4.5 资料维护与运行边界

增量导入是追加新内容，重建是用完整的目标资料集合替换现有库。同名新版不会自动删除旧版；需要去掉旧版时，应准备全部要保留的资料再重建。如果批量重建时有文件无效，它可能被跳过，成功入库的有效集合仍会替换原库，因此必须核对导入报告。

导入失败保护主要覆盖单次活动更新与写盘失败，不涵盖所有突然断电、磁盘损坏、多个进程同时写入或人为删除。重要资料应保留原文件与独立备份。Atomic replace 有助于避免半写文件，但不是完整的备份策略。

页面历史记录与磁盘知识库生命周期不同。刷新或新会话后，资料索引可以恢复，聊天记录和页面密钥可能丢失。向量模型不变时无需因为聊天密钥丢失而重新上传全部文件，只要补齐配置即可继续检索。

默认本机监听减少意外暴露，但这不是用户认证。如果要部署到服务器，不能仅将地址改为 0.0.0.0 就声称支持多人使用；还需要身份认证、独立存储路径、并发写保护、网络访问控制和日志管理。

4.6 项目特色与可陈述的工程成果

本项目的特点是以较小的代码规模实现了可追溯的完整 RAG 流程，明确区分离线与 API 行为，并把模型配置一致性、失败保护和页面异常路径纳入工程实现。它的价值主要是完整性、可理解性和可复现性，不宜包装成新的基础检索算法或模型训练成果。

与只演示“上传后能回答”的最小脚本相比，本项目额外处理了文件编码、真实页码、哈希去重、配置错配、持久化、流式中断和同名版本预览等问题。每项特色都应对应代码位置和测试证据，而不是只写抽象的“高效、智能、可靠”。

可以陈述“完成可运行的文档知识库问答原型，支持 PDF/TXT 导入、向量检索、流式回答和参考原文展示，具备本地恢复与自动化验证”。若要进一步陈述节省检索时间、提高正确率等效果，需要先完成本报告第三章所述的质量与耗时评测。

第五章 总结与后续完善

5.1 项目完成情况

项目已经实现文档读取、文本清洗、递归分段、向量生成、FAISS 精确检索、上下文构建、模型流式调用与来源展示，并具备本地持久化、增量去重、配置签名和导入失败保护。离线模式为无密钥演示提供了可复现路径，模拟 HTTP 和页面测试为接口及交互提供了回归依据。

从工程学习角度，项目把自然语言处理、向量数学、API 协议、状态管理、存储一致性和软件测试连接起来。理解这些环节之间的依赖，比单独会调用某个模型 SDK 更重要：没有正确文本，就没有可靠向量；没有一致向量空间，就没有可解释排序；没有证据与界面核对，生成答案仍可能误导。

5.2 后续改进顺序

表 5-1 后续改进顺序

优先级	改进方向	预期解决的问题	建议验证方式
第一阶段	固定题集与真实问答验收	量化当前能力，发现主要错误来源	分题型记录检索、支持程度与耗时
第二阶段	版式感知解析与 OCR	扫描、双栏、表格资料难以准确抽取	人工对照原页，检查抽取与定位
第二阶段	混合检索与重排序	专有名词、数值或语义改写排序不佳	同题集对比 Recall@K 和 MRR
第二阶段	邻接片段与来源去重	边界信息丢失，重叠片段挤占预算	检查跨段问题和上下文有效覆盖
第三阶段	token 预算与引用校验	输入预算粗糙，引用编号可能不可靠	检查实际用量及逐条引用支持

优先级	改进方向	预期解决的问题	建议验证方式
第三阶段	文档删除与多版本索引	维护旧版依赖完整重建	验证删除后向量与元数据一致
部署阶段	鉴权、隔离、并发与备份	个人原型无法直接供多人共享	权限、并发写入和恢复演练

这些方向属于后续计划，不是当前版本的已实现功能。应优先解决实际资料中的主要错误，再决定是否增加复杂组件。没有评测基线时，增加重排序器或更换索引类型很难证明收益。

5.3 推荐学习与讲解路线

先运行离线示例，观察输入、片段和来源；再阅读 documents.py，弄清文档如何变成带 metadata 的 Document；随后阅读 providers.py 和 knowledge_base.py，理解同模型编码、归一化、向量位置与原文映射；最后阅读 qa.py 和 app.py，理解证据如何进入 Prompt、回答如何流式显示以及状态如何恢复。

讲解时可以围绕“用户问 FAISS 如何实现余弦检索”这一具体问题串起全流程，再解释三项设计取舍：为什么先分段再建库、为什么向量双侧归一化、为什么导入先构造候选索引后提交。最后用实际测试和当前限制说明系统能保证什么、还需要验证什么。

附录 A 核心代码阅读索引

表 A-1 附录 A 核心代码阅读索引

阅读位置	核心对象或函数	建议关注的内容
rag/config.py	Settings.from_env / validate	环境变量后备、合法参数和调用时密钥要求
rag/config.py	Settings.index_signature	哪些配置变化需要重建，哪些不需要
rag/documents.py	InputFile.safe_name / digest	文件名清理和原始字节哈希
rag/documents.py	read_document / clean_text	PDF 页码、TXT 编码与规范化边界
rag/documents.py	split_documents	分隔符、起点、顺序和片段 ID

阅读位置	核心对象或函数	建议关注的内容
rag/providers.py	DemoEmbeddings / UnitEmbeddings	词面哈希与真实语义模型的区别、归一化
rag/providers.py	build_embeddings / build_chat_model	两套 API 参数及兼容接口选项
rag/knowledge_base.py	KnowledgeBase.ingest	去重、候选索引、替换模式和提交时机
rag/knowledge_base.py	KnowledgeBase._save / load	NPZ 结构、校验、临时文件和恢复
rag/knowledge_base.py	KnowledgeBase.search	查询维度、Top-K 和阈值
rag/qa.py	prepare_answer / stream_answer	证据预算、Prompt、空证据与流式输出
rag/errors.py 与 app.py	user_error / 会话及预览逻辑	敏感错误信息保护、状态生命周期、同名版本

以下伪代码用于串联概念，省略了实际实现中的异常、报告、预算和校验，不能直接替代项目代码。

```
# Indexing
pages = read_and_clean(upload)
chunks = split_with_metadata(pages)
vectors = normalize(embedding.embed_documents(chunks))
candidate = clone_or_create_index()
candidate.add(vectors, chunks)
save_then_activate(candidate)

# Question answering
query = normalize(embedding.embed_query(question))
hits = top_k_then_threshold(index.search(query))
context, displayed_sources = build_budgeted_context(hits)
if not displayed_sources:
    return no_evidence_message
return stream(prompt(context, question), chat_model)
```

附录 B 部署演示与故障排查

B.1 本机启动与配置

项目现有虚拟环境可以直接启动。在新的电脑上，应先创建虚拟环境并安装依赖；需要复现报告环境时可使用 requirements-lock.txt。PowerShell 命令如下。

```
cd D:\RAG
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe -m streamlit run app.py
```

打开 http://127.0.0.1:8501，默认使用离线模式。先点击“加载示例资料”，再提问“FAISS 如何实现余弦相似度检索？”，展开参考片段核对来源。API 问答需要在左侧应用两套服务配置，或者按 .env.example 创建本机 .env 后重启。

对于当前已保存的 API 索引，Embedding Base URL 为 https://api.siliconflow.cn/v1，模型名为 BAAI/bge-m3，分段长度/重叠长度为 600/100。保留这些参数、补齐自己密钥后可以恢复当前索引，无需再次为相同资料生成文档向量。聊天模型名应填写实际账户可用值，本报告不以示例模型名保证供应商可用性。

B.2 建议演示顺序

1. 展示页面中的运行模式、文档数与片段数，明确离线或 API。
2. 导入一份有效资料，检查新增数量、解析警告和文档预览。
3. 提出资料中有答案的问题，查看回答与文件、页码和原文。
4. 在配置允许的情况下验证资料不足场景，说明阈值和 Prompt 的边界。
5. 重复导入相同文件，检查去重；新会话打开后检查索引恢复。
6. 导出问答记录，说明数据来源与当前尚未实现的功能。

如果展示生成式回答，应提前用实际服务完成一次可核对的问答，不应把离线原文摘录作为大模型生成的演示。报告截图中的离线标识应保留。



图 B-1 当前页面的离线问答与参考片段。 该画面用于说明交互方式，不代表真实问答模型生成结果。

B.3 常见现象与定位顺序

表 B-1 常见现象与定位顺序

现象	优先检查	处理思路
PDF 没有文本	是否扫描件、页面是否有文本层	先 OCR，再导入具有文本层的 PDF
导入时返回网页	Base URL 是否控制台网页	改为向量服务 API 前缀
HTTP 401	对应服务密钥与权限	核对问答和向量服务是否填反
HTTP 429	额度、速率或并发限制	查看供应商账户，减少请求并稍后重试
HTTP 400 / 404	模型名、前缀、输入和接口类型	按服务文档逐项核对，必要时减小批量
旧库不兼容	Embedding 地址模型或分段是否变化	恢复原设置，或选齐资料重建

现象	优先检查	处理思路
检索内容无关	抽取质量、问题主题、模型与阈值	先查中间片段，再按题集调整参数
回答中断	网络、超时或服务响应	将已显示内容视为未完成，重试并核对
新会话密钥为空	是否仅在页面填写	重新填写；需要持久配置时使用本机 .env

B.4 自动化检查命令

```
.\.venv\Scripts\python.exe -m pytest -q
.\.venv\Scripts\python.exe -m ruff check app.py rag tests
.\.venv\Scripts\python.exe -m pip check
```

系统临时目录不可写时，可按 README 把 TEMP、TMP 和 pytest 的 basetemp 指向项目 .cache 内目录。若受限执行环境阻止 Streamlit 本机套接字或 FAISS 原生库加载，应在正常本机环境运行验证，不应通过改动业务逻辑掩盖环境问题。

附录 C 项目理解与答辩问题

C.1 RAG 与微调有什么区别

本项目的文档知识保存在外部片段与向量索引中，提问时检索后临时提供给模型。微调则通过训练更新模型参数。RAG 更便于增补资料和展示来源，但其效果依赖解析、分段、检索与生成各环节。本项目没有微调，也没有训练自己的向量模型。

C.2 为什么 FAISS 不能直接回答问题

FAISS 接收向量并返回相似向量的位置与分数，不理解页面如何展示引用，也不生成自然语言。原文来自 Document 列表，回答来自聊天模型；把三者连接起来才构成完整问答系统。

C.3 为什么相同维度仍可能不能混用

维度只说明向量有多少个分量，不说明分量的语义或训练得到的空间结构。不同模型的坐标空间可能完全不同。项目通过地址、模型名和预处理配置签名减少混用，并通过实际维度检查发现返回形状变化。

C.4 怎么减少幻觉与误导

先提高原文和检索质量，避免无证据时仍然生成；再设置资料边界、缺证据说明与引用要求；最后展示实际输入模型的原文，允许用户核对。项目已经实现这些基础措施，但没有证明完全防止幻觉，后续应增加题集评测和逐条引用支持检查。

C.5 为什么不一开始就使用复杂 Agent

当前需求的数据流明确：读文件、检索、组织资料、生成回答。固定管线更容易观察和测试。只有后续出现需要动态选择工具、跨步骤规划或多数据源操作的明确需求，才有充分理由增加 Agent 编排。

C.6 怎样描述自己的实际工作

应先讲用户问题，再讲实现动作与验证证据，例如“完成文档读取与分段，保留来源；对接独立的向量和聊天接口；使用归一化向量与 FAISS 检索；通过页面展示回答和原文；补充持久化与异常回归测试”。结果描述限于已经验证的原型能力，不把计划功能、接口模拟或估算容量写成真实业务成绩。

参考资料

以下在线资料查阅日期均为 2026 年 10 月 12 日。实现细节以当前项目代码为准，第三方服务可用模型与价格以实际账户为准。

[R1] Lewis P, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. 2020. https://arxiv.org/abs/2005.11401

[R2] LangChain. Splitting recursively. https://docs.langchain.com/oss/python/integrations/splitters/recursive_text_splitter

[R3] LangChain. OpenAIEmbeddings integration. https://docs.langchain.com/oss/python/integrations/embeddings/openai

[R4] FAISS. MetricType and distances. https://github.com/facebookresearch/faiss/wiki/MetricType-and-distances

[R5] FAISS. Faiss indexes. https://github.com/facebookresearch/faiss/wiki/Faiss-indexes

[R6] LangChain. ChatOpenAI integration. https://docs.langchain.com/oss/python/integrations/chat/openai

[R7] pypdf. Extract Text from a PDF. https://pypdf.readthedocs.io/en/stable/user/extract-text.html

[R8] Streamlit. Session State. https://docs.streamlit.io/develop/api-reference/caching-and-state/st.session_state

[R9] Streamlit. AppTest. https://docs.streamlit.io/develop/api-reference/app-testing/st.testing.v1.apptest

[P1] 本地项目代码：app.py，rag/config.py，rag/documents.py，rag/providers.py，rag/knowledge_base.py，rag/qa.py，rag/errors.py。

[P2] 本地验证资料：tests/ 中五个测试文件，README.md，requirements-lock.txt，docs/演示与验收.md，以及 data/indices/api/knowledge.npz 的规模与配置元数据。

[F1] 用户提供的 PhonoShield 作品报告，2026 年 10 月 7 日。仅参考封面、目录、摘要、章节层级及 A4 中文报告版式，技术内容仍对应本 RAG 项目。